

## Universidade Federal do Paraná



Laboratório de Estatística e Geoinformação - LEG

# Métodos de reamostragem

Profs.: Eduardo Vargas Ferreira Walmes Marques Zeviani


## Validação cruzada e bootstrap



- Nesta seção vamos discutir dois métodos de reamostragem: validação cruzada e bootstrap;
- Tais métodos reajustam o modelo de interesse a partir de amostras dos dados de treino, a fim de obter informações adicionais sobre o modelo;
- Por exemplo, fornecem estimativas do erro de predição da amostra de teste, o vício e desvio padrão das estimativas dos parâmetros;
- Lembrando:
  - \* Erro de validação: média do erro resultante da predição de uma nova observação (que não fazia parte dos dados de treino);
  - Erro do treino: é calculado mediante aplicação do método estatístico nos dados de treino.


## Separação dos dados





## Dados de treino x Dados de validação





## Validação cruzada holdout



 Nesta abordagem dividimos os dados em apenas duas partes: treinamento e validação;




- O modelo é ajustado utilizando os dados de treinamento, e com o modelo obtido fazemos predições nas observações dos dados de validação;
- O erro resultante dos dados de validação fornece uma estimativa do erro do teste, baseando-se em determinado indicador;
- Tipicamente, utilizamos o erro quadrado médio para variáveis quantitativas e taxa de classificação incorreta para as qualitativas;

### Exemplo: Auto data set



- Queremos comparar polinômios de diferentes ordens em uma regressão linear;
- Separamos aleatoriamente as 392 observações em duas amostras: treinamento (com 196 dados) e validação (196 dados);



O gráfico da esquerda temos divisão única e da direita divisão múltipla.

# Inconvenientes desta abordagem de validação



- A estimativa do erro, dependendo do conjunto de treinamento e validação, pode ser altamente variável;
- Lembre-se, nesta abordagem apenas uma parte da amostra treino (aquela não utilizada no treinamento) é utilizada para prever o erro;
- Esse fato sugere que a estimativa do erro do teste será superestimada, pois o tamanho da amostra será pequeno com relação aos dados totais;

Menos dados ⇒ geralmente menos informação ⇒ maior variabilidade

 Para minimizar esses problemas, outras abordagens de validação cruzada surgiram, uma delas é por k-fold;

## Validação cruzada por k - fold




- k-fold é amplamente usado para estimar o erro do teste;
- As estimativas podem ser usadas para seleção do melhor modelo, e fornecer uma ideia do erro do teste para o modelo escolhido;
- O método consiste em dividir os dados em k partes iguais. Ajusta-se o modelo com k-1 partes, e uma é destinada para às predições;
- Isto é feito para cada parte  $k=1,\ldots,K$ , e em seguida os resultados são combinados;

1	2	3	4	5
Validation	Train	Train	Train	Train

## **Validação cruzada** 5 — fold





# Validação cruzada por k - fold




- Sejam as K partes denotadas por C<sub>1</sub>, C<sub>2</sub>,..., C<sub>K</sub>, em que C<sub>k</sub> representa o
  índice da k-ésima parte;
- Considere que temos  $n_k$  observações na parte k (se n é múltiplo de K, então  $n_k = n/K$ );
- Calcule:

$$CV_{(K)} = \sum_{k=1}^{K} \frac{n_k}{n} EQM_k.$$

- O  $EQM_k = \sum_{i \in C_k} (y_i \hat{y}_i)^2 / n_k$ , e  $\hat{y}_i$  é o valor ajustado da observação i, obtido dos dados com a parte k removida;
- Um caso particular é quando K = n gerando o método leave-one-out cross-validation (LOOCV).

### Leave-one-out cross-validation






## Exemplo: Auto data set




O gráfico da direita apresenta 9 diferentes validações cruzadas 10 – fold.
 Em cada uma temos uma nova partição dos dados;



 Note que a variabilidade é menor quando comparado com a abordagem holdout (slide 6);



 O gráfico abaixo apresenta a verdadeira curva do MSE em azul, a estimativa LOOCV pontilhada e 10 – fold em laranja;



- No primeiro gráfico as curvas estimadas têm o comportamento correto, todavia subestima o erro quadrado médio;
- Da mesma forma, no gráfico central, as estimativas estão muito próximas do valor real quando os graus de flexibilidade do modelo são baixos.

### Bias-Variance Trade-Off



 Um bom desempenho de um método em um conjunto de teste requer um baixo erro quadrático médio. Porém, note que

$$\mathrm{E}\left[y_0 - h(x_0)\right]^2 = \mathrm{Var}\left[h(x_0)\right] + \left[\mathrm{Vicio}(h(x_0))\right]^2 + \mathrm{Var}(\varepsilon). \tag{1}$$

#### Variância

- Refere-se ao quanto h(x<sub>0</sub>) muda quando a estimamos utilizando diferentes dados de treino;
- Idealmente as estimativas de h(x<sub>0</sub>) n\u00e3o deveriam mudar muito entre os conjuntos;
- \* Em geral, quanto mais flexível o modelo, maior a variância.


#### Vício

- Refere-se ao erro de aproximar um problema real (extremamente complicado) por uma função simples;
- \* Em geral, quanto mais simples o modelo, maior o vício.

### **Bias-Variance Trade-Off**



• Os três gráficos abaixo ilustram a Equação (1):



- \* A curva azul representa o  $[\text{Vicio}(h(x_0))]^2$ , para diferentes níveis de flexibilidade:
- \* A curva laranja a  $Var[h(x_0)]$ ;
- $\star$  A linha pontilhada  $Var(\varepsilon)$ , o erro irredutível;
- \* Finalmente, a linha vermelha representa o EQM do teste.

# CV em problemas de classificação



- Sejam as K partes denotadas por C<sub>1</sub>, C<sub>2</sub>,..., C<sub>K</sub>, em que C<sub>k</sub> representa o
  índice da k-ésima parte;
- Considere que temos  $n_k$  observações na parte k (se n é múltiplo de K, então  $n_k = n/K$ );
- Calcule:

$$CV_{(K)} = \sum_{k=1}^{K} \frac{n_k}{n} Err_k$$
, com  $Err_k = \sum_{i \in C_k} \mathbb{1}(y_i \neq \hat{y}_i)/n_k$ .


O desvio padrão estimado do CV<sub>k</sub> é

$$\widehat{\mathit{DP}}(\mathit{CV}_k) = \sqrt{\sum_{k=1}^{\mathit{K}} \left(\mathit{Err}_k - \overline{\mathit{Err}}_k 
ight)^2 / (\mathit{K} - 1)}$$

 Que é uma estimativa útil, mas não muito válida (existe correlação entre os desvios, pois compartilham parte da amostra de treino).



- Os dados consistem em 100 observações;
- Classificadas em um dos 2 grupos (indicados em azul e laranja);
- Ajustamos quatro modelos de regressão logística aos dados;
- P. ex., um modelo quadrático fica:




$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \beta_3 X_2 + \beta_4 X_2^2$$

A verdadeira taxa de erro do teste é 0.133 (são dados simulados!).





 A taxa de erro do teste para os quatro ajustes são, respectivamente, 0.201, 0.197, 0.160, e 0.162.






- Na prática, em dados reais, a verdadeira taxa de erro do teste são desconhecidas;
- Então, como decidir entre os modelos propostos? Validação cruzada;
- Abaixo temos a taxa de erro por validação cruzada 10 fold em preto, o verdadeiro erro do teste em marrom e o erro do treinamento em azul;
- Na esquerda temos o classificador por regressão logística. E na direita, utilizamos KNN (nas abscissas temos o inverso do número de vizinhos).









- Analisando os gráficos percebemos que a taxa de erro do treinamento decresce com o aumento da flexibilidade do modelo;
- Na esquerda, a taxa de erro do teste apresenta uma forma de U.
   Semelhante à validação cruzada 10 fold (com uma boa aproximação);
- Na direita, a taxa do erro por validação cruzada também apresenta um mínimo muito próximo do obtido com os dados de teste.


### CV: certo e errado



- Considere um classificador aplicado aos dados de duas classes:
  - Começando com 500000 preditoras e amostra de tamanho 50, filtramos as 100 preditoras que têm maior correlação nas classes;
  - 2 Aplicamos um classificador (e.g. regressão logística) utilizando somente as 100 preditoras.
- Como podemos estimar o desempenho do teste para este classificador?
   Validação cruzada
- Podemos aplicar validação cruzada no Passo 2, esquecendo o Passo 1 (não incorporando o fato de termos eliminado 4900 preditoras)? Não!
  - \* Isso seria ignorar o fato de que no Passo 1 o procedimento já viu os rótulos de treinamento, e aprendeu com isso.


## Errado!





## Certo!






### **Bootstrap**



- Bootstrap é uma ferramenta utilizada para quantificar a incerteza associada a determinado estimador ou método de aprendizagem;
- Por exemplo, pode ser usado para estimar o erro padrão dos coeficientes do ajuste de uma regressão linear (ou seus intervalos de confiança);
- Na verdade, o poder do bootstrap reside no fato de ser aplicável em uma vasta gama de métodos estatísticos;
- Incluindo alguns para os quais uma medida de variação é difícil de obter (e não é fornecido automaticamente pelo software);

## Ideia básica do bootstrap






## Exemplo com somente 3 observações



 Cada conjunto de dados bootstrap contém n observações amostradas com reposição dos dados originais.



### Bootstrap estimando o erro de predição



 Na validação cruzada, o K- ésimo fold de validação é distinto dos demais k - 1 folds usados no treinamento;



- Não há overlap entre os dados de treino e validação. O que é crucial para seu sucesso. Queremos uma ideia sobre os dados de teste (novos dados);
- Para estimar o erro utilizando bootstrap, podemos pensar em separar cada amostra bootstrap para treinamento e a original como validação;
- Entretanto, tais amostras apresentam um significativo overlap com os dados originais (cerca de 2/3);
- Este fato causa sérios problemas de subestimação do verdadeiro erro de predição (podendo ser parcialmente solucionado - não veremos no curso);
- Então, validação cruzada apresenta uma abordagem mais simples e atrativa para estimar o erro de predição (Keep it simple!).