

Universidade Federal do Paraná Laboratório de Estatística e Geoinformação - LEG




Classificação

Profs.: Eduardo Vargas Ferreira Walmes Marques Zeviani

Introdução



- Em muitos problemas, a variável Y assume valores em um conjunto não ordenado \mathcal{C} , por exemplo:
 - \star E-mail $\in \{\text{spam}, \text{ham}\};$
 - ⋆ Dígito $∈ {0, 1, ..., 9};$
 - ★ Alzheimer ∈ {com Alzheimer, sem Alzheimer};
- Nestes casos, estamos diante de um problema de classificação;



Introdução



• Considere um problema binário, em que Y assume somente dois valores, c_1 ou c_2 . Para um dado x, escolheremos c_1 quando

$$P(Y = c_1|\mathbf{x}) \geq P(Y = c_2|\mathbf{x}),$$

 Tal classificador é conhecido como Classificador de Bayes. Escolhemos nossa função, tal que,

$$h(x) = \underset{d \in \{c_1, c_2\}}{\operatorname{argmax}} P(Y = d|x).$$

 Note que agora, o custo baseado na distância entre a resposta observada e estimada não faz mais sentido. Ao invés dele, é comum utilizar

$$J(h) = P[Y \neq h(X)].$$

• Assim, ainda que $h(x) \in \mathbb{R}^+$, ela representará a escolha por uma classe.

Plug-in classifier



• Entretanto, não conhecemos tais probabilidades:

O classificador de Bayes é um padrão ouro inalcançável!

• A solução é então estimar $P(Y=c_i|\mathbf{x})$, para $i\in\mathcal{C}$, ou seja

- ★ Estimamos P(Y = c|x) para cada categoria $c \in C$;
- * Tomamos $h(x) = \underset{c \in \mathcal{C}}{\operatorname{argmax}} \widehat{P}(Y = c|x).$


Essa abordagem é conhecida como plug-in classifier.


K-Nearest Neighbors



• O KNN estima a distribuição condicional de Y|X de acordo com as classes dos K vizinhos de determinada observação x_0 , ou seja:

$$P(Y=j\mid X=x_0)=\frac{1}{K}\sum_{i\in\mathcal{N}_0}\mathbb{I}(y_i=j).$$






K-Nearest Neighbors




• A escolha de K tem um efeito drástico no classificador KNN obtido



K-Nearest Neighbors




 Temos que escolhê-lo de acordo com o resultado do teste. A linha pontilhada representa o classificador de Bayes.




Exemplo: Inadimplência no cartão de crédito (1929)



- Neste exemplo, nosso objetivo é prever se um cliente será ou não inadimplente no próximo mês;
- Para tanto, temos três variáveis explicativas:
 - * Estudante: se o cliente é ou não estudante;
 - * Rendimento: rendimento anual do cliente;
 - * Saldo: o valor devido no mês atual.





Podemos utilizar regressão linear?




 Suponha que para classificação da variável Inadimplente codificamos da forma:


$$Y = egin{cases} 0, & ext{se Não} \ 1, & ext{se Sim} \ . \end{cases}$$

- Podemos simplesmente realizar uma regressão linear de Y em X e classificar como Sim se $\hat{Y} > 0.5$?
 - * Considerando o fato de que $\mathrm{E}\left(Y|X=x\right)=\mathrm{P}\left(Y=1|X=x\right)$, podemos pensar que regressão é ótima para isto!
 - No caso de resposta binária, regressão linear faz um bom trabalho (equivalente à análise de discriminante linear);
 - * Entretanto, ela pode produzir probabilidades menores do que 0 ou maiores do que 1. Regressão logística é mais apropriada.

Regressão logística







• Denotando por p(X) = P(Y = 1|X). A regressão logística utiliza a forma

$$p(X) = \frac{e^{\beta_0 + \beta_1 X}}{1 + e^{\beta_0 + \beta_1 X}}.$$

• Assim, não importa os valores de β_0 e β_1 ou X, $p(X) \in (0,1)$.

Regressão logística



• Com um pouco de algebrismo chegamos em

$$log\left(\frac{p(X)}{1-p(X)}\right)=\beta_0+\beta_1X.$$

• Que é chamada \log odds ou transformação \log em p(X).

Variável	Coeficiente	Desvio padrão	Estatística t	p-valor
Intercepto	-10,6513	0,3612	-29,5	< 0,0001 < 0,0001
Saldo	0,0055	0,0002	24,9	

 Qual é a probabilidade estimada de Inadimplente para um cliente com Saldo de \$1000?

$$\hat{\rho}(\mathbf{X}) = \frac{e^{\hat{\beta}_0 + \hat{\beta}_1 X}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_1 X}} = \frac{e^{-10,6513 + 0,0055 \times 1000}}{1 + e^{-10,6513 + 0,0055 \times 1000}} = 0,006.$$

Regressão logística



• Vamos repetir o processo anterior, agora com Estudante como preditor;

Variável	Coeficiente	Coeficiente Desvio padrão Estatística <i>t</i>		p-valor	
Intercepto Estudante[Sim]	-3,5041 0,4049	0,0707 0.1150	-49,55 3.52	< 0,0001 0.0004	
Estudante[Sim]	0,4049	0,1150	3,52	0,0	

$$\widehat{\mathrm{P}}\left(\mathtt{Inadimplente=Sim}|\mathtt{Estudante=Sim}\right) = \frac{e^{-3,5041+0,4049\times1}}{1+e^{-3,5041+0,4049\times1}} = 0,0431.$$

$$\widehat{P}\left(\mathtt{Inadimplente=Sim} | \mathtt{Estudante=N\~ao} \right) = \frac{e^{-3,5041+0,4049\times0}}{1+e^{-3,5041+0,4049\times0}} = 0,0292.$$

Regressão logística com várias variáveis



Agora o caso de mais de um preditor, o modelo geral torna-se

$$log\left(\frac{p(X)}{1-p(X)}\right)=\beta_0+\beta_1X_1+\ldots+\beta_pX_p.$$

е

$$p(\pmb{X}) = rac{e^{eta_0 + eta_1 X_1 + \ldots + eta_p X_p}}{1 + e^{eta_0 + eta_1 X_1 + eta_p X_p}}.$$


Variável	Coeficiente	te Desvio padrão Estatística (p-valor
Intercepto	-10,8690	0,4923	-22,08	< 0,0001
Saldo	0,0057	0,0002	24,74	< 0,0001
Rendimento	0,0030	0,0082	0,37	0,7115
Estudante[Sim]	-0,6468	0,2362	-2,74	0,0062

 Por que o coeficiente de Estudante é negativo agora, enquanto era positivo anteriormente? Confundimento.

Confundimento



 Os resultados são diferentes, especialmente quando existe correlação entre os preditores (veja o gráfico da direita);



- Estudantes [Sim] tendem a ter maior Saldo do cartão de crédito;
- Assim, marginalmente a taxa de Inadimplência é maior do que não Estudantes [Não];
- Por outro lado, para cada nível do Saldo mensal, a inadimplência dos estudantes é menor (gráfico da esquerda).

Outra abordagem



- Uma alternativa para estimar P(Y|X) consiste em modelar a distribuição de X em cada classe separadamente;
- E utilizar o **Teorema de Bayes** para obter P(Y|X);

$$P(Y = k|X = x) = \frac{P(Y = k)P(X = x|Y = k)}{P(X = x)}$$

• Que escrevendo de outra forma fica

$$P(Y = k|X = x) = \frac{\pi_k f_k(x)}{\sum_{l=1}^{K} \pi_l f_l(x)}$$


Então temos que


$$\delta_k(x) \propto argmax \ \pi_k f_k(x)$$

Outra abordagem



- $f_k(x) = P(X = x | Y = k)$ é a densidade para X na classe k (diferentes distribuições levam a diferentes métodos);
- π_k = P(Y = k) é a probabilidade marginal ou priori para classe k. Pode ser estimada utilizando as proporções amostrais em cada classe.
- Para diferentes prioris em cada classe, temos diferentes decisões;






Análise de discriminante




• Ao considerarmos para $f_k(x)$ a distribuição Normal em cada classe, nos leva à análise de discriminante linear ou quadrática, pois

$$\begin{array}{lll} \delta_k(x) & \propto & \operatorname{argmax} \ \pi_k f_k(x) \\ & = & \operatorname{argmax} \left\{ \log \pi_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} \langle x - \mu_k, \Sigma_k^{-1}(x - \mu_k) \rangle \right\}. \end{array}$$

- $\langle x \mu_k, \Sigma_k^{-1}(x \mu_k) \rangle$ é a Distância de Mahalanobis de x e μ_k ;
- Por exemplo, seja $\mu_1 = -1.5, \mu_2 = 1.5, \pi_1 = \pi_2 = 0.5$ e $\sigma^2 = 1$





Análise de discriminante



 Quando f_k(x) possui matriz de covariância, Σ_k, diferente em cada classe, temos a análise de discriminante quadrático (ADQ)

$$\begin{array}{lll} \delta_k(x) & \propto & \operatorname{argmax} \ \pi_k f_k(x) \\ & = & \operatorname{argmax} \left\{ \log \pi_k - \frac{1}{2} \log |\Sigma_k| - \frac{1}{2} (x - \mu_k)^t \Sigma_k^{-1} (x - \mu_k) \right\}. \end{array}$$

- Note a ocorrência do termo quadrático na distância de Mahalanobis;
- Se todas as classes compartilharem o mesmo $\Sigma = \sum_k \frac{n_k 1}{n K} \hat{\Sigma}_k$, estamos diante da análise de discriminante linear (ADL)


$$\begin{array}{lll} \delta_k(x) & \propto & \operatorname{argmax} \ \pi_k f_k(x) \\ & = & \operatorname{argmax} \left\{ \log \pi_k - \frac{1}{2} \mu_k^t \Sigma^{-1} \mu_k + x^t \Sigma^{-1} \mu_k \right\}. \end{array}$$

• Em ADL, o termo quadrático é cancelado.

Análise de discriminante



 Utilizamos, assim, os dados de treino para estimar tais quantidades e incorporar à regra de decisão, da seguinte forma



$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:y_i = k} x_i$$

$$\hat{\Sigma}_k = \frac{1}{n_k - 1} \sum_{i:y_i = k} (x_i - \hat{\mu}_k) (x_i - \hat{\mu}_k)^t$$

Regressão logística versus ADL



- Regressão logística e análise de discriminante linear diferem-se na forma de estimar os parâmetros:
 - * Regressão logística maximiza a verossimilhança condicional

$$\prod_{i} p(x_{i}, y_{i}) = \underbrace{\prod_{i} p(y_{i}|x_{i})}_{logistica} \underbrace{\prod_{i} g(x_{i})}_{ignorado}$$

* ADL maximiza a verossimilhança completa


$$\prod_{i} p(x_{i}, y_{i}) = \underbrace{\prod_{i} p(x_{i}|y_{i})}_{normal \ f_{k}} \underbrace{\prod_{i} p(y_{i})}_{bernoulli \ \pi_{k}}$$

Mas na prática, os resultados são similares.

llustração: p = 2 e k = 3 classes




• No exemplo abaixo, temos $\pi_1 = \pi_2 = \pi_3 = 1/3$;



 A linha pontilhada é conhecida como fronteira de decisão de Bayes (Bayes decision boundaries);

Exemplo: Iris Data






Exemplo: Iris Data



Temos 4 variáveis, 3 espécies com 50 observações em cada classe;




 Análise de discriminante linear classifica corretamente 147/150 observações dos dados de treino.

Exemplo simulado: Bayes, ADL e ADQ




- No exemplo, temos a fronteira de decisão de Bayes em rosa, ADL pontilhado e ADQ em verde, em um problema com 2 classes;
- No gráfico da esquerda $\Sigma_1 = \Sigma_2$ e o da direita $\Sigma_1 \neq \Sigma_2$;



Qual classificador escolher?




- Cenário 1: 20 observações em cada classe. Todas não correlacionadas e normalmente distribuídas;
- Cenário 2: Semelhante ao cenário 1, mas em cada classe, os preditores têm correlação de -0,5;
- Cenário 3: Semelhante ao cenário 1, mas com distribuição t de student.



Qual classificador escolher?



- Cenário 4: Os dados são normalmente distribuídos, com correlação de 0,5 em uma classe e -0,5 em outra;
- Cenário 5: As respostas foram geradas utilizando os preditores: X_1^2 , X_2^2 e $X_1 \times X_2$ (ou seja, limite de decisão quadrático);
- Cenário 6: As respostas foram geradas utilizando funções não lineares mais elaboradas.



Naive bayes



- Vimos que quando f_k(x) tem distribuição Normal com mesma variância Σ temos ADL. E se temos variâncias diferentes em cada classe temos ADQ;
- Agora, se supusermos que as componentes de x são independentes condicionalmente à classe Y estamos diante do Naive Bayes;
- Naive Bayes assume distribuição normal, com Σ_k diagonal:

$$\delta_k(x) \propto log\left[\pi_k \prod_{j=1}^{
ho} f_{kj}(x_j)
ight] = -rac{1}{2} \sum_{j=1}^{
ho} rac{(x_j - \mu_{kj})^2}{\sigma_{kj}^2} + log(\pi_k).$$

 Apesar de tal suposição não ser razoável em muitos problemas (Naive = Ingênuo) ela é conveniente, e leva a bons classificadores.

Tipos de erro



• Voltando ao exemplo do cartão de crédito, temos a seguinte situação:

		Inadi: Não	mplênc Sim	ia observado Total
Inadimplência predito	Não Sim	9644 23	252 81	9896 104
	Total	9667	333	10000

Falso positivo: fração de exemplos negativos classificados como positivo;

Falso negativo: fração de exemplo positivo classificado como negativo;

• Construímos esta tabela classificando a classe como Sim se

$$\widehat{P}(Inadimplencia = Sim \mid Saldo, Estudante) \ge 0, 5.$$

Será que o limiar de 0,5 é a melhor opção?


Variando o threshold



 Podemos mudar as taxas de erro, alterando a fronteira de decisão para algum valor ∈ [0, 1]:

$$\widehat{P}(Inadimplencia = Sim \mid Saldo, Estudante) \ge threshold.$$


 Abaixo, em azul temos a taxa de falso negativo, em laranja falso positivo e em preto a taxa de erro total.



Curva ROC



 A curva ROC (receiver operator characteristic) nos ajuda nesta escolha do threshold. Ela apresenta as duas taxas de erro ao mesmo tempo.



Referências



- James, G., Witten, D., Hastie, T. e Tibshirani, An Introduction to Statistical Learning, 2013;
- Hastie, T., Tibshirani, R. e Friedman, J., The Elements of Statistical Learning, 2009;
- Lantz, B., Machine Learning with R, Packt Publishing, 2013;
- Tan, Steinbach, and Kumar, Introduction to Data Mining, Addison-Wesley, 2005;
- Some of the figures in this presentation are taken from "An Introduction to Statistical Learning, with applications in R" (Springer, 2013) with permission from the authors: G. James, D. Witten, T. Hastie and R. Tibshirani