

Universidade Federal do Paraná Laboratório de Estatística e Geoinformação - LEG



Aprendizado não supervisionado

Profs.: Eduardo Vargas Ferreira Walmes Marques Zeviani

Métodos de aprendizagem não supervisionada



- Vamos discutir dois métodos:
 - * Análise de Componentes Principais: tenta explicar a estrutura de covariância através de combinações lineares de X_1, X_2, \dots, X_p ;
 - Clustering: se trata de uma ampla classe de métodos para descobrir agrupamentos nos dados.
- Exemplos:
 - Pacientes com câncer agrupados de acordo com similaridades nas expressões gênicas;
 - Grupos de consumidores caracterizados pelos seus históricos de navegação e compras;
 - * Filmes agrupados pelas notas dos espectadores.

Análise de Componentes Principais (ACP)



- Suponha que temos X₁, X₂,..., X_p. Então, temos p variáveis para reproduzir a variabilidade geral do sistema;
- Porém, é possível que parte dessa variabilidade seja explicada por um número mínimo k
- Componentes principais são as sequências de combinações lineares de X₁, X₂,..., X_p que maximizam a sua variância;
- Genericamente, representa um novo sistema de coordenadas, rotacionando o original com X₁, X₂,..., X_ρ como coordenadas;
- Os novos eixos representam as direções de máxima variabilidade, de forma mais parcimoniosa para descrever a estrutura de covariância;

Análise de Componentes Principais (ACP)



• A primeira componente principal de um conjunto de características X_1, X_2, \ldots, X_p é a combinação linear normalizada $(\sum_{j=1}^p \phi_{j1}^2 = 1)$

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \ldots + \phi_{p1}X_p,$$


em que $\phi_1 = [\phi_{11}, \dots, \phi_{p1}]^t$ são as cargas da 1ª c.p.;

- Elas maximizam a $Var(Z_1) = \phi_1^t \Sigma \phi_1$, em que Σ é a matriz de covariância de $X = [X_1, \dots, X_p]^t$;
- A normalização deve-se ao fato da $Var(Z_1)$ aumentar a medida que ϕ_1 aumenta, assim eliminamos esta inconveniência;
- A segunda componente principal φ₂^tX maximiza Var(φ₂^tX), sujeito a restrição φ₂^tφ₂ = 1 e Cov(φ₁^tX, φ₂^tX) = 0;
- A i-ésima componente principal φ_i^tX maximiza Var(φ_i^tX), sujeito a restrição φ_i^tφ_i = 1 e Cov(φ_k^tX, φ_i^tX) = 0, ∀k < i.

ACP: exemplo



 O gráfico abaixo retrata o tamanho da população versus gasto com publicidade em 100 diferentes cidades;



Exemplo: USAarrests data




- Os dados contém o número de prisões por 100.000 residentes nos 50 estados dos Estados Unidos;
- As prisões decorrem de: Assalto, Assassinato ou Estupro;
- Registrou-se, também, o percentual da população vivendo em área urbana de cada estado (População urbana);
- Dessa forma, temos n = 50 e p = 4.
- No gráfico a seguir são apresentadas as duas primeiras componentes principais para o dados em questão.

Exemplo: USAarrests data



 Os dados contém o número de prisões por 100.000 residentes nos 50 estados dos Estados Unidos;




Os nomes em azul representam o escore para as duas c.p.

Escalando as variáveis



 Se as variáveis estão em diferentes unidades é recomendável escalar cada uma para se ter um desvio padrão igual a 1.



Proporção da variância explicada




• A variância total presente nos dados é definida como


$$\sum_{j=1}^{p} extstyle extstyle Var(oldsymbol{X}_j) = \lambda_1 + \lambda_2 + \ldots + \lambda_p = \sum_{j=1}^{p} extstyle Var(oldsymbol{Z}_j)$$

 Assim, a proporção da variância explicada pela j-ésima componente principal é dada por

$$\frac{\lambda_j}{\lambda_1 + \lambda_2 + \ldots + \lambda_p}$$

 Abaixo, a proporção da variância explicada por cada uma das quatro c.p. referente ao USAarrests data;





Clustering



- Clustering refere-se ao conjunto de técnicas para encontrar subgrupos (ou clusters) a partir dos dados;
- Buscamos partições em grupos distintos, tal que observações dentro de cada grupo sejam similares entre si e diferentes dos demais;
- Veremos dois métodos:
 - * K-means clustering: procuramos partições dos dados em um número pré-determinado de clusters;
 - Hierarchical clustering: não sabemos de antemão quantos clusters utilizaremos. Isso será feito através de uma representação visual;
 - * DBSCAN: um algoritmo de cluster baseado em densidades.

K-means




 A ideia do K-means é buscar agrupamentos, tal que a variação dentro de cada cluster seja tão pequena quanto possível;

Algoritmo

- ★ Step 1: Atribua, aleatoriamente, cada observação em um dos K clusters (este é o chute inicial);
- * Step 2: Itere até que os clusters se estabilizem:
 - (a) Para cada K cluster, calcule seu centroide;
 - (b) Atribua cada observação ao cluster mais próximo (menor distância Euclideana).

Detalhes do algoritmo






Exemplo simulado




 Os dados simulados consistem em 150 observações. Os painéis representam os resultados de K-means para diferentes K's;



Hierarchical Clustering




- Como vimos, k-means exige que preespecifiquemos o número de clusters.
 O que pode ser uma desvantagem;
- Hierarchical clustering é uma abordagem alternativa, que não exige comprometimento com a escolha de K;



 A ideia é construir um dendrograma com folhas que se agrupam até chegar ao tronco;

Ideia do algoritmo






- Iniciamos com cada ponto sendo seu próprio cluster;
- Identificamos os dois clusters mais próximos e os agrupamos;
- Repetimos este processo até restar um cluster.

Ideia do algoritmo






- Iniciamos com cada ponto sendo seu próprio cluster;
- Identificamos os dois clusters mais próximos e os agrupamos;
- Repetimos este processo até restar um cluster.

Ideia do algoritmo






- Iniciamos com cada ponto sendo seu próprio cluster;
- Identificamos os dois clusters mais próximos e os agrupamos;
- Repetimos este processo até restar um cluster.

Exemplo




• Temos 45 observações, e 3 classes distintas (separadas por cores);





Exemplo



 Abaixo, três dendrogramas com diferentes alturas de corte (que resulta em clusters distintos);







Tipo de Linkage



Complete

 Calculamos a máxima dissimilaridade entre os clusters.



$$L(r,s) = \max(D(x_{ri}, x_{si}))$$

Single

 Calculamos a mínima dissimilaridade entre os clusters.



$$L(r,s) = \min(D(x_{ri}, x_{si}))$$

Average

 Calculamos a dissimilaridade média entre os clusters.




$$L(r,s) = \frac{1}{n_r n_s} \sum_{i=1}^{n_r} \sum_{j=1}^{n_s} D(x_{ri}, x_{sj})$$

Exemplo

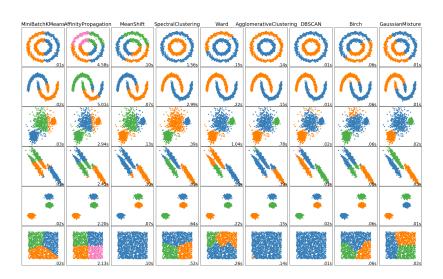


 Em geral, average e complete linkage tendem a produzir agrupamentos mais equilibrados.



Outros tipos de clusters






DBSCAN



 Os métodos que vimos anteriormente são adequados para encontrar agrupamentos esféricos, em regiões bem definidas e ausentes de outliers.



 Entretanto, no mundo real, os clusters podem ter formas arbitrárias (oval, em forma de "S" etc.), e virem com outliers e ruídos.

DBSCAN




- DBSCAN (Density-Based Spatial Clustering and Application with Noise)
 é um algoritmo de cluster baseado em densidade;
- A ideia básica da abordagem é derivada do método intuitivo humano de diferenciar regiões no espaço:

Clusters são regiões densas, separadas por regiões de menor densidade.

- Temos dois parâmetros de tuning:
 - \star eps: que define o raio, ϵ , em torno do ponto x;
 - * MinPts: número mínimo de vizinhos dentro do raio ϵ .

Como o método funciona





- Qualquer ponto x, com uma quantidade de vizinhos maior ou igual a MinPts é considerado core;
- O ponto pertence a fronteira se o número de vizinhos < MinPts, mas está contido no raio de algum core;
- Finalmente, se o ponto não é interior nem de fronteira, ele é considerado como ruído ou outlier

Prós e contras do método



Vantagens

- Não requer um número predefinido de clusters;
- Podem ser de qualquer forma, incluindo não esféricos;
- A técnica é capaz de identificar dados de ruído (outliers).


Desvantagem

- Pode falhar se não houver queda de densidade entre clusters;
- É sensível aos parâmetros que definem a densidade de tuning;
- A configuração adequada pode exigir conhecimento e domínio.


K-means vs DBSCAN




 No exemplo abaixo, comparamos DBSCAN com o k-means, através do conjunto de dados simulados.






















Reachability Plot



Reachability-plot





Referências



- James, G., Witten, D., Hastie, T. e Tibshirani, An Introduction to Statistical Learning, 2013;
- Hastie, T., Tibshirani, R. e Friedman, J., The Elements of Statistical Learning, 2009;
- Lantz, B., Machine Learning with R, Packt Publishing, 2013;
- Tan, Steinbach, and Kumar, Introduction to Data Mining, Addison-Wesley, 2005;
- Some of the figures in this presentation are taken from "An Introduction to Statistical Learning, with applications in R" (Springer, 2013) with permission from the authors: G. James, D. Witten, T. Hastie and R. Tibshirani